

Cvičné úlohy ke státnicím

Úroveň 2 (doplněk k úrovni 1; úroveň 1+2 dohromady > 95 %)

Informatika - Umělá inteligence, zaměření Strojové učení (UI-SU) | MFF UK

Aditivní díl: obsahuje **POUZE** rozšíření úrovně 2. Nejdříve zvládní úroveň 1.

Co je tohle a proč to zvedá pravděpodobnost

Tři sešity jsou **aditivní**: úroveň 1 ($\approx 92\%$) + tento díl = $\approx 95\%$; po přidání úrovně 3 $\approx 97,5\%$. Tady jsou jen *nové* úlohy úrovně 2 - jádro (definice, 2-bodové zálohy) je v úrovni 1. Vázající je podlaha specializace ($\geq 7/12$, tři ze čtyř otázek na ≥ 2 body), takže hlavní páka je **snížit pravděpodobnost skóre 0-1 u pokryté otázky**. Tento díl proto přidává:

- **Numerické varianty** vysokovynosových témat (k-means a entropie ručně, rekonstrukce matice záměn, ROC/AUC, krok SGD, PCA, inference v Bayes síti, filtrace HMM, EM update, alfa-beta/A*, iterace hodnot MDP, AC-3);
- **Důkazové náčrty** (pumping pro CFL, Master theorem, NP-úplnost, dolní odhad třídění, Eulerova formule, tablo);
- **Těžší implementační úlohy** společné informatiky (alokátor, FAT, dvouúrovňové stránkování, překlad konstrukcí).

Modelově to posune $P(\text{ML} \leq 1)$ z $\approx 15\%$ na $\approx 5\%$ a celkové $P(\text{složím})$ z $\approx 92\%$ na $\approx 95\%$. Zelené *Jádro* na 2 body je minimum k zapamatování; u numerických úloh počítej na papír a pak odkryj.

Obsah

1 Společná matematika (rozšíření)	1
2 Společná informatika (rozšíření)	4
3 Specializace: Strojové učení (rozšíření)	9
4 Specializace: Základy UI (rozšíření)	14

1 Společná matematika (rozšíření)

Úloha 1. **společná matematika** [úroveň 2] **Pozitivně definitní matice, Sylvester a Choleského rozklad**

Matice $A = \begin{pmatrix} 4 & 2 \\ 2 & 3 \end{pmatrix}$.

- 1 b** Definujte pozitivně definitní matici a uveďte Sylvestrovo kritérium a vztah k vlastním číslům.
- 2 b** Rozhodněte, zda je A pozitivně definitní.
- 3 b** Spočtete Choleského rozklad $A = LL^T$.

(a) Symetrická A je *pozitivně definitní*, pokud $x^T A x > 0$ pro každé $x \neq 0$. Ekvivalentně: všechna vlastní čísla jsou kladná; nebo (*Sylvestrovo kritérium*) všechny hlavní rohové minory jsou kladné. Pak existuje jednoznačný *Choleského rozklad* $A = LL^T$ s dolní trojúhelníkovou L s kladnou diagonálou.

(b) Rohové minory: $4 > 0$ a $\det A = 4 \cdot 3 - 2 \cdot 2 = 8 > 0$. Obě kladné $\Rightarrow A$ je pozitivně definitní. (Kontrola přes vlastní čísla: stopa 7, determinant 8, $\lambda = \frac{7 \pm \sqrt{17}}{2} \approx 5,56; 1,44 > 0$.)

(c) $A = LL^T$, $L = \begin{pmatrix} l_{11} & 0 \\ l_{21} & l_{22} \end{pmatrix}$: $l_{11} = \sqrt{4} = 2$; $l_{21} = a_{21}/l_{11} = 2/2 = 1$; $l_{22} = \sqrt{a_{22} - l_{21}^2} = \sqrt{3 - 1} = \sqrt{2}$. Tedy

$$L = \begin{pmatrix} 2 & 0 \\ 1 & \sqrt{2} \end{pmatrix}, \quad LL^T = \begin{pmatrix} 4 & 2 \\ 2 & 3 \end{pmatrix} = A.$$

Úloha 2.3.1. (dodatek k úloze 2.3)

PD $\iff$ vlastní čísla $> 0 \iff$ všechny rohové minory > 0 (Sylvester). Cholesky: $l_{11} = \sqrt{a_{11}}$, $l_{21} = a_{21}/l_{11}$, $l_{22} = \sqrt{a_{22} - l_{21}^2}$.

Kalibrace: Pozitivní definitnost + Cholesky je doslova v požadavku a opakuje se v lineární algebře (skalární součin, pozitivně definitní matice). Sylvester + jeden rozklad = 2-3 body.

Pozor (častá chyba): Sylvester vyžaduje *rohové* (leading) minory, ne libovolné. Pozitivní semidefinitní připouští nulové vlastní číslo (minory ≥ 0).

Úloha 2. **společná matematika** [úroveň 2] **Určité integrály: obsah, objem, substituce**

(a) **1 b** Spočtete $\int_0^1 (3x^2 + 2x) dx$.

(b) **2 b** Spočtete obsah plochy mezi křivkami $y = x$ a $y = x^2$ na $[0, 1]$ a objem tělesa vzniklého rotací $y = x$ kolem osy x na $[0, 1]$.

(c) **3 b** Spočtete $\int_0^1 x e^{x^2} dx$ substitucí.

(a) $\int_0^1 (3x^2 + 2x) dx = [x^3 + x^2]_0^1 = 1 + 1 = 2$.

(b) Na $[0, 1]$ je $x \geq x^2$, takže obsah $= \int_0^1 (x - x^2) dx = [\frac{x^2}{2} - \frac{x^3}{3}]_0^1 = \frac{1}{2} - \frac{1}{3} = \frac{1}{6}$. Objem rotace $y = x$ kolem osy x : $V = \pi \int_0^1 x^2 dx = \pi [\frac{x^3}{3}]_0^1 = \frac{\pi}{3}$.

(c) Substituce $u = x^2$, $du = 2x dx$, tedy $x dx = \frac{1}{2} du$; meze $x: 0 \rightarrow 1$ dají $u: 0 \rightarrow 1$:

$$\int_0^1 x e^{x^2} dx = \frac{1}{2} \int_0^1 e^u du = \frac{1}{2} [e^u]_0^1 = \frac{e-1}{2} \approx 0,859.$$

Úloha 2.3.2. (dodatek k úloze 2.3)

Obsah $= \int_a^b (\text{horní} - \text{dolní}) dx$; objem rotace kolem osy $x = \pi \int_a^b f(x)^2 dx$. Substituce: zaveď u , přepiš dx i meze. $\int_0^1 x e^{x^2} = \frac{e-1}{2}$.

Kalibrace: Obsah/objem a substituce jsou opakované výpočetní podotázky analýzy (45 %). Jeden bezchybný integrál = 2 body do podlahy společných okruhu.

Pozor (častá chyba): U obsahu mezi křivkami integruj *rozdíl* (horní minus dolní) a hlídej, která je nahoře. U substituce přepiš i meze, jinak musíš vracet zpět do x .

Úloha 3. **společná matematika** [úroveň 2] **Pravděpodobnost numericky: Bayes a centrální limitní věta**

(a) **1 b** Nemoc má prevalenci $P(D) = 0,01$. Test má $P(+ | D) = 0,99$ a $P(+ | \neg D) = 0,05$. Spočtete $P(D | +)$.

(b) **2 b** Interpretujte výsledek (proč je tak nízký).

- (c) **3 b** Pomocí CLT odhadněte $P(\text{součet } 100 \text{ hodů kostkou} > 380)$. (Pro jednu kostku $\mathbb{E}X = 3,5$, $\text{var } X = \frac{35}{12}$.)

(a) Bayes:

$$P(D | +) = \frac{P(+ | D)P(D)}{P(+ | D)P(D) + P(+ | \neg D)P(\neg D)} = \frac{0,99 \cdot 0,01}{0,99 \cdot 0,01 + 0,05 \cdot 0,99} = \frac{0,0099}{0,0594} \approx 0,167.$$

(b) I při velmi přesném testu je posterior jen $\approx 16,7\%$, protože nemoc je vzácná: falešně pozitivních ze zdravé většiny ($0,05 \cdot 0,99 \approx 0,0495$) je víc než pravdivě pozitivních ($0,0099$). Nízká prevalence (base rate) sráží posterior.

(c) Součet $S = \sum_{i=1}^{100} X_i$: $\mathbb{E}S = 100 \cdot 3,5 = 350$, $\text{var } S = 100 \cdot \frac{35}{12} \approx 291,7$, $\sigma_S \approx 17,08$. Dle CLT je S přibližně normální, takže $z = \frac{380-350}{17,08} \approx 1,76$ a $P(S > 380) \approx P(Z > 1,76) \approx 0,039$.

Bayes: posterior $\propto$ věrohodnost $\times$ prior; u vzácných jevu pozor na base rate. CLT: součet/průměr nezávislých je přibližně $\mathcal{N}$; $\mathbb{E}S = n\mu$, $\text{var } S = n\sigma^2$, standardizuj $z = \frac{x-\mathbb{E}S}{\sigma_S}$.

Kalibrace: Bayes numericky a CLT aplikace jsou opakované (pravděpodobnost 25 %, CLT se zkoušela 2025-léto). Dosazení do vzorce = 2 body.

Pozor (častá chyba): Rozptyl součtu je $n\sigma^2$, směrodatná odchylka $\sqrt{n}\sigma$ (ne $n\sigma$). U Bayese nezapomeň na jmenovatel přes úplnou pravděpodobnost.

Úloha 4. **společná matematika** [úroveň 2] **Eulerova formule (důkaz) a Mengerova věta**

- (a) **1 b** Zformulujte Eulerovu formuli pro souvislý rovinný graf a naznačte její důkaz indukcí.
 (b) **2 b** Odvoďte $E \leq 3V - 6$ a pomocí toho ukažte, že K_5 není rovinný.
 (c) **3 b** Zformulujte hranovou a vrcholovou verzi Mengerovy věty.

(a) Pro souvislý rovinný graf platí $V - E + F = 2$. *Důkaz indukcí podle počtu hran:* kostra (strom) má $E = V - 1$ a $F = 1$, takže $V - (V - 1) + 1 = 2$ platí. Přidáním hrany, která uzavře kružnici, vznikne nová stěna: E i F vzrostou o 1, takže $V - E + F$ se nezmění. Indukcí platí pro každý souvislý rovinný graf.

(b) U jednoduchého grafu s $V \geq 3$ ohraničuje každou stěnu ≥ 3 hran a každá hrana sousedí se 2 stěnami, tedy $2E \geq 3F$. Dosazením $F = 2 - V + E$: $2E \geq 3(2 - V + E) = 6 - 3V + 3E$, odkud $E \leq 3V - 6$. Pro K_5 : $V = 5$, $E = \binom{5}{2} = 10$, ale $3V - 6 = 9 < 10$, takže K_5 nesplňuje nutnou podmínku rovinnosti $\Rightarrow$ není rovinný.

(c) *Mengerova věta (hranová):* minimální počet hran, jejichž odebrání rozpojí vrcholy u, v , se rovná maximálnímu počtu *hranově disjunktních* cest mezi u, v . *Vrcholová verze* (pro různé *nesousední* vrcholy u, v): minimální počet vrcholu (různých od u, v), jejichž odebrání rozpojí u, v , se rovná maximálnímu počtu *vnitřně vrcholově disjunktních* cest mezi u, v .

$V - E + F = 2$ (souvislý rovinný), důkaz indukcí přes hrany (kružnicová hrana přidá stěnu). Důsledek $E \leq 3V - 6$ vylučuje K_5 . Menger: min. řez = max. počet disjunktních cest (hranová/vrcholová verze).

Kalibrace: Eulerova formule, rovinnost a Menger jsou opakovaný grafový okruh (45 %); úroveň 2 přidává důkaz, který zkouška může chtít. Náčrt důkazu = 3. bod.

Pozor (častá chyba): $E \leq 3V - 6$ platí pro jednoduché grafy $V \geq 3$ (bipartitní: $E \leq 2V - 4$). Mengerova věta je grafový protějšek max-flow/min-cut.

Úloha 5. **společná matematika** [úroveň 2] **Tablo metoda a věty o kompaktnosti a úplnosti**

- (a) **1 b** Popište princip tablo metody (důkaz sporem, rozkladová pravidla, uzavřená větve).
- (b) **2 b** Tablo metodou ukažte, že $((p \rightarrow q) \wedge p) \rightarrow q$ je tautologie.
- (c) **3 b** Zformulujte větu o kompaktnosti a větu o úplnosti a vysvětlete jejich význam.

(a) *Tablo* dokazuje tautologii sporem: předpokládá, že formule *neplatí*, a rozkládá ji *rozkladovými pravidly* na složky (konjunktivní pravidla větvev prodlouží, disjunktivní ji rozvětví). Větvev se *uzavře*, obsahuje-li formuli i její negaci. Uzavřou-li se všechny větvev, je výchozí předpoklad sporný, takže formule je tautologie.

(b) Předpokládáme nepravdivost: $\neg((p \rightarrow q) \wedge p) \rightarrow q$, což znamená $(p \rightarrow q) \wedge p$ pravdivé a q nepravdivé. Z konjunkce: $p \rightarrow q$ pravdivé, p pravdivé, $\neg q$. Z $p \rightarrow q$ (disjunkce $\neg p \vee q$) se větvev rozdělí: větvev s $\neg p$ se uzavře (máme p i $\neg p$); větvev s q se uzavře (máme q i $\neg q$). Všechny větvev uzavřené $\Rightarrow$ tautologie.

(c) *Věta o kompaktnosti*: teorie má model právě tehdy, když má model každá její konečná podmnožina. *Věta o úplnosti*: $T \models \varphi$ (sémantický důsledek) právě tehdy, když $T \vdash \varphi$ (existuje formální důkaz). Význam: úplnost spojuje pravdivost ve všech modelech s odvoditelností v kalkulu (dokazatelnost „dohoní“ platnost); kompaktnost umožňuje přenášet vlastnosti z konečných částí na celek (časté u nekonečných teorií).

Tablo = důkaz sporem: rozkládej negaci cíle, uzavři větvev při X i $\neg X$; všechny uzavřené $\Rightarrow$ tautologie. Kompaktnost: model existuje $\iff$ pro každou konečnou podmnožinu. Úplnost: $\models \iff \vdash$.

Kalibrace: Logika (znění vět o kompaktnosti/úplnosti, tablo/rezoluce) je v požadavku a je levná na definice. Úroveň 2 přidává jeden vyřešený tablo důkaz.

Pozor (častá chyba): Tablo dokazuje sporem - začínáš *negací* dokazované formule. Úplnost ($\models \iff \vdash$) nezaměňuj s korektností (jen $\vdash \Rightarrow \models$).

2 Společná informatika (rozšíření)

Úloha 6. **společná informatika** [úroveň 2] **Jednoduchý správce paměti (alokátor haldy)**

Implementujte jednoduchý alokátor nad souvislým polem bajtu (haldou).

- (a) **1 b** Popište reprezentaci: blok s hlavičkou (velikost + příznak volný/obsazený) a volný seznam.
- (b) **2 b** Napište **Alloc** strategií first-fit (včetně rozdělení bloku) a **Free** (včetně slučování sousedu).
- (c) **3 b** Vysvětlete vnitřní a vnější fragmentaci a roli zarovnání (alignment).

(a) Halda je posloupnost bloku; každý má *hlavičku* s velikostí a příznakem, zda je volný. Volné bloky lze provázat do *volného seznamu*. Z ukazatele na data se k hlavičce dostaneme odečtením

její velikosti.

(b)

```
// hlavička: int Size; bool Free; (uložena před daty)
IntPtr Alloc(int n) {
    n = Align(n, 8); // zarovnání požadavku
    for (var b = first; b != null; b = b.Next)
        if (b.Free && b.Size >= n) {
            if (b.Size >= n + MinBlock) // rozděl velký blok
                Split(b, n);
            b.Free = false;
            return b.Data;
        }
    return IntPtr.Zero; // nenalezeno
}

void Free(Block b) {
    b.Free = true;
    if (b.Next != null && b.Next.Free) Coalesce(b, b.Next); // sluč vpravo
    if (b.Prev != null && b.Prev.Free) Coalesce(b.Prev, b); // sluč vlevo
}
```

(c) *Vnitřní fragmentace*: blok je větší než požadavek (kvůli zarovnání / minimální velikosti), nevyužitý zbytek leží uvnitř bloku. *Vnější fragmentace*: volná paměť je roztržštěná do malých kousků, takže velký souvislý požadavek selže, ač je celkem dost místa. *Zarovnání*: data daného typu musí začínat na adrese dělitelné jejich velikostí (rychlejší/korektní přístup CPU), proto se velikosti zaokrouhlují nahoru.

Blok = hlavička (velikost + volný?) + data. First-fit: první dost velký volný blok, případně rozděl. Free: označ volný a slučuj se sousedy. Fragmentace: vnitřní (zbytek v bloku) vs vnější (roztříštěné volno).

Kalibrace: Implementační otázka ze společné informatiky (alokátor) padla 2025-léto; je to typ, na kterém „naoko připravený“ propadá. Definice + kostra Alloc/Free = vyhnutí se nule.

Pozor (častá chyba): Po Free nezapomeň slučovat sousední volné bloky (jinak vnější fragmentace roste). Hlavička zabírá místo - počítej s ní u malých alokací.

Úloha 7. **společná informatika** [úroveň 2] **Souborový systém typu FAT**

Souborový systém ukládá soubor jako řetěz bloku spojený tabulkou FAT (každá položka udává číslo *dalšího* bloku, nebo značku konce EOF, nebo FREE).

- (a) **1b** Popište, jak FAT reprezentuje soubor a jak se pozná konec a volné bloky.
- (b) **2b** Soubor začíná blokem 2 a tabulka je: FAT[2]=5, FAT[5]=7, FAT[7]=EOF. Vypište bloky souboru v pořadí. Jak se přidá blok na konec?
- (c) **3b** Jaké jsou nevýhody FAT (fragmentace, náhodný přístup) a jak je řeší inody/extenty?

(a) Adresář drží u souboru číslo *prvního* bloku. Položka FAT[i] udává číslo bloku následujícího po bloku i; speciální hodnota EOF značí poslední blok, FREE značí volný blok. Řetězením od prvního bloku se přečte celý soubor.

(b) Od bloku 2: 2 → FAT[2]=5 → FAT[5]=7 → FAT[7]=EOF. Bloky souboru: **2, 5, 7**. Přidání bloku: najdi volný blok (např. k s FAT[k]=FREE), nastav FAT[7]=k a FAT[k]=EOF.

(c) *Nevýhody*: soubor bývá rozházený po disku (vnější fragmentace, pomalé čtení), a *náhodný přístup* na n-tý blok vyžaduje projít řetěz od začátku ($O(n)$). *Inody* drží pole přímých (a

nepřímých) odkazu na bloky, takže přístup k libovolnému bloku je rychlý; *extenty* popisují souvislé úseky (start + délka), což šetří metadata a zrychluje sekvenční čtení.

FAT[i] = další blok řetězu (nebo EOF/FREE). Čtení = řetěz od prvního bloku z adresáře. Slabina: náhodný přístup $O(n)$ a fragmentace; inody/extenty to řeší přímými odkazy/souvislými úseky.

Kalibrace: FAT / interní struktura souborového systému padla 2020-podzim. Sledování řetězu bloku + nevýhody = 2 body z implementační otázky.

Pozor (častá chyba): FAT položka ukazuje na *další* blok, není to bitmapa volných (to je jiná struktura). Náhodný přístup je u FAT lineární, ne konstantní.

Úloha 8. **společná informatika** [úroveň 2] **Stránkování, překlad adresy a ochrana paměti**

16bitová virtuální adresa, velikost stránky 256 B. Virtuální adresa je 0x1234.

- (a) **1 b** Rozdělte adresu na číslo stránky a offset.
- (b) **2 b** Jednoúrovňová stránkovací tabulka mapuje stránku 0x12 na rámec 0x07. Spočtete fyzickou adresu.
- (c) **3 b** Vysvětlíte roli virtuálních adresových prostorů v ochraně paměti procesu.

(a) Stránka 256 B $\Rightarrow$ offset má $\log_2 256 = 8$ bitů. $0x1234 = 0001\ 0010\ 0011\ 0100_2$: offset (dolních 8 bitů) = 0x34, číslo stránky (horních 8 bitů) = 0x12.

(b) Stránka 0x12 $\rightarrow$ rámec 0x07. Fyzická adresa = (rámec $\ll 8$) | offset = $0x07 \ll 8$ | 0x34 = 0x0734.

(c) Každý proces má vlastní stránkovací tabulku, tedy vlastní mapování virtuálních adres na rámce; nevidí proto fyzickou paměť jiných procesů (*izolace*). Přístup na nenamapovanou stránku vyvolá výpadek (page fault) a OS proces ochrání/ukončí. Tím virtuální adresový prostor zajišťuje ochranu paměti mezi procesy.

(Nad rámec požadavku - jen pro přehled:) u velkých adresových prostorů se používají víceúrovňové tabulky (alokují podtabulky jen pro použité oblasti, šetří paměť) a TLB (cache nedávných překladů stránka $\rightarrow$ rámec).

Adresa = (číslo stránky || offset); offset má $\log_2(\text{velikost stránky})$ bitů. Fyzická = rámec $\ll$ (bity offsetu) | offset. Virtuální adresový prostor (vlastní tabulka na proces) zajišťuje izolaci/ochranu paměti.

Kalibrace: Překlad adres jednoúrovňovou tabulkou + ochrana paměti jsou přesně v požadavku a opakovaně se zkouší (virtuální paměť, architektura/OS 60 %). Rozdělení adresy + výpočet rámce = 2-3 body.

Pozor (častá chyba): Offset má tolik bitů, kolik je $\log_2(\text{velikost stránky})$. Fyzická adresa skládá rámec (ne číslo stránky) s offsetem.

Úloha 9. **společná informatika** [úroveň 2] **Překlad konstrukcí vyššího jazyka do instrukcí**

- (a) **1 b** Jak se na úrovni instrukcí procesoru realizuje přiřazení, podmínka a cyklus?
- (b) **2 b** Přeložte do pseudo-assembleru cyklus `i=0; while (i<n) { sum += a[i]; i++; }`.
- (c) **3 b** Jak se realizuje volání funkce (zásobníkový rámec, `call/ret`, návratová hodnota)?

(a) *Přiřazení* = výpočet do registru a *store* do paměti (nebo *load* při čtení). *Podmínka* = porovnání (*cmp*) následované podmíněným skokem (*jl*, *je*, ...). *Cyklus* = test podmínky + podmíněný skok zpět na začátek těla.

(b)

```

mov i, 0 ; i = 0
mov sum, 0 ; sum = 0
loop: cmp i, n ; porovnej i a n
      jge end ; if (i >= n) goto end
      mov r1, a[i] ; r1 = a[i] (adresa = base + i*velikost)
      add sum, r1 ; sum += r1
      add i, 1 ; i++
      jmp loop ; zpet na test
end: ...

```

(c) *Volání funkce*: volající uloží argumenty (do registru / na zásobník) dle volací konvence a provede *call* (uloží návratovou adresu na zásobník a skočí). Volaná funkce si vytvoří *zásobníkový rámec* (uloží starý base pointer, vyhradí místo pro lokální proměnné), vykoná tělo, výsledek dá do dohodnutého registru (např. *eax*), obnoví rámec a *ret* (vyzvedne návratovou adresu a skočí zpět).

Přiřazení = load/store; podmínka = *cmp* + podmíněný skok; cyklus = skok zpět na test. Volání = *call* (uloží návratovou adresu) + rámec na zásobníku + *ret*; výsledek v dohodnutém registru.

Kalibrace: Překlad konstrukcí na instrukce padl 2022-léto. Cyklus/podmínka -> skoky a princip volání = 2 body z implementační/architektonické otázky.

Pozor (častá chyba): Podmínka cyklu se testuje na začátku (u *while*); skok je podmíněný ven a nepodmíněný zpět. *call* ukládá návratovou adresu, *ret* ji vyzvedává.

Úloha 10. společná informatika [úroveň 2] Pumping lemma pro bezkontextové jazyky a Master theorem

- (a) **1 b** Zformulujte pumping lemma pro bezkontextové jazyky (CFL).
- (b) **2 b** Dokažte, že $L = \{a^n b^n c^n \mid n \geq 0\}$ není bezkontextový.
- (c) **3 b** Vysvětlete hlavní myšlenku Master theoremu (rekurzni strom) a jeho tři případy. (Požadavek uvádí Master theorem „bez důkazu” - formální důkaz se nevyžaduje, jen pochopení.)

(a) Pro každý CFL existuje p tak, že každé slovo $w \in L$ s $|w| \geq p$ lze psát $w = uvxyz$, kde $|vxy| \leq p$, $|vy| \geq 1$ a pro každé $i \geq 0$ je $uv^i xy^i z \in L$. (Pumpují se dva úseky najednou.)

(b) Sporem: necht L je CFL s konstantou p a $w = a^p b^p c^p$. Rozklad $w = uvxyz$ s $|vxy| \leq p$ znamená, že vxy zasahuje nejvýše dva ze tří bloku (a, b, c) - nemůže obsahovat a i c , neboť mezi nimi je p symbolů b . Napumpováním ($i = 2$) se zvýší počet symbolů jen v jednom či dvou blocích, takže přestanou být všechny tři stejně početné: $uv^2 xy^2 z \notin L$. Spor, L není CFL.

(c) Master theorem ($T(n) = aT(n/b) + f(n)$) přes *rekurzni strom*: na úrovni i je a^i podproblému velikosti n/b^i , práce mimo rekurzi na úrovni i je $a^i f(n/b^i)$; listu je $a^{\log_b n} = n^{\log_b a}$. Sečtením úrovní rozhoduje, zda dominují listy ($n^{\log_b a}$), kořen ($f(n)$), nebo jsou úrovně vyrovnané (pak faktor $\log n$). Konkrétně pro $f(n) = \Theta(n^c)$ ($a \geq 1, b > 1$) porovnej c s $\log_b a$: $c < \log_b a \Rightarrow \Theta(n^{\log_b a})$ (listy); $c = \log_b a \Rightarrow \Theta(n^c \log n)$; $c > \log_b a \Rightarrow \Theta(n^c)$ (kořen, za podmínky regularity). To jsou tři případy věty.

CFL pumping: $w = uvxyz$, $|vxy| \leq p$, $|vy| \geq 1$, $uv^i xy^i z \in L$. $\{a^n b^n c^n\}$: vxy pokryje max 2 bloky $\Rightarrow$ pumpování rozváží třetí. Master theorem: porovnej $n^{\log_b a}$ (listy) s $f(n)$.

Kalibrace: Důkaz nebezkontextovosti (přes pumping) podpírá zařazení do Chomského hierarchie - to je v požadavku. Master theorem se dle požadavku umí použít (bez důkazu); intuice rekurzního stromu je jen pro pochopení.

Pozor (častá chyba): CFL pumping pumpuje dva úseky (v a y) zároveň, na rozdíl od regulárního (jeden). Klíč u $a^n b^n c^n$ je $|vxy| \leq p$ (nepokryje krajní bloky současně).

Úloha 11. společná informatika [úroveň 2] NP-úplnost: redukce 3-SAT na kliku

- (a) **1 b** Co je potřeba dokázat, aby byl problém NP-úplný? Co je polynomiální redukce?
- (b) **2 b** Popište redukci $3\text{-SAT} \leq_p \text{KLIKA}$ (konstrukci grafu).
- (c) **3 b** Zdůvodněte korektnost (formule splnitelná $\iff$ graf má kliku dané velikosti) a polynomiálnost.

(a) Problém B je NP-úplný, pokud (1) $B \in \text{NP}$ (existuje polynomiálně ověřitelný certifikát) a (2) B je NP-těžký: každý problém z NP se na B polynomiálně redukuje ($\forall K \in \text{NP} : K \leq_p B$). V praxi (díky tranzitivitě $\leq_p$) stačí zredukovat jeden známý NP-úplný problém na B . Polynomiální redukce $A \leq_p B$ je v polynomiálním čase vyčíslitelná funkce převádějící instance A na instance B se zachováním odpovědi ano/ne.

(b) Dáno 3-CNF s m klauzulemi. Pro každou klauzuli vytvoř trojici vrcholu (po jednom za každý literál). Hranou spoj dva vrcholy z různých klauzulí, pokud si jejich literály neodporují (nejsou to x a $\neg x$). Uvnitř téže klauzule hrany nevedou. Ptáme se na kliku velikosti m .

(c) **Korektnost:** klika velikosti m musí obsahovat právě jeden vrchol z každé klauzule (uvnitř klauzule hrany nejsou) a vybrané literály se navzájem neodporují - lze je tedy všechny nastavit na pravda konzistentním ohodnocením, které splní každou klauzuli. Naopak ze splňujícího ohodnocení vyber v každé klauzuli jeden pravdivý literál; tyto vrcholy jsou po dvou spojené (neodporují si) a tvoří kliku velikosti m . **Polynomiálnost:** graf má $3m$ vrcholu a $O(m^2)$ hran, konstrukce běží v polynomiálním čase.

NP-úplný = v NP + NP-těžký (redukce ze známého NP-úplného). $3\text{-SAT} \leq_p \text{KLIKA}$: vrchol za literál v klauzuli, hrana mezi neodporujícími literály různých klauzulí, hledej kliku velikosti = počet klauzulí.

Kalibrace: Konkrétní redukce (důkaz NP-úplnosti) je legální 3. bod u otázky o složitosti. Úroveň 2 přidává jeden vzorový převod.

Pozor (častá chyba): Směr redukce: ze známého těžkého (3-SAT) na nový (KLIKA). Hrany vedou mezi neodporujícími literály různých klauzulí; klika má velikost počtu klauzulí.

Úloha 12. společná informatika [úroveň 2] Dolní odhad porovnávacího třídění

- (a) **1 b** Popište model rozhodovacího stromu pro porovnávací třídící algoritmy.
- (b) **2 b** Dokažte dolní odhad $\Omega(n \log n)$ na počet porovnání.
- (c) **3 b** Proč platí dolní mez jen pro porovnávací model? (Nesrovnávací algoritmy jako counting/radix sort ji obcházejí - stačí zmínit.)

(a) Porovnávací algoritmus lze popsat *rozhodovacím stromem*: vnitřní uzel je porovnání dvou prvků ($a_i \leq a_j$), větve odpovídají výsledku, list odpovídá jedné konkrétní permutaci (výslednému uspořádání). Běh algoritmu = cesta od kořene k listu; počet porovnání v nejhorším případě = výška stromu.

(b) Pro n prvků existuje $n!$ možných uspořádání, a protože algoritmus musí umět rozlišit každé, má strom aspoň $n!$ listů. Binární strom s L listy má výšku $\geq \log_2 L$, tedy výška $\geq \log_2(n!)$. Stirlingovým vzorcem $\log_2(n!) = \Theta(n \log n)$. Výška = nejhorší počet porovnání, takže každý porovnávací algoritmus potřebuje $\Omega(n \log n)$ porovnání.

(c) *Nesrovnávací* algoritmy nepoužívají porovnání dvojic, ale strukturu klíče: *counting sort* pro celá čísla z malého rozsahu k spočítá četnosti a umístí prvky, $O(n + k)$; *radix sort* třídí po číslicích pomocí stabilního counting sortu, $O(d(n + k))$. Tím obcházejí dolní mez $\Omega(n \log n)$, která platí jen pro *porovnávací* model.

Rozhodovací strom má $\geq n!$ listů $\Rightarrow$ výška $\geq \log_2(n!) = \Theta(n \log n) \Rightarrow$ porovnávací třídění je $\Omega(n \log n)$. Counting/radix sort tuto mez obchází (nepoužívají porovnání), za cenu předpokladu o rozsahu klíče.

Kalibrace: Dolní odhad třídění je opakované téma (třídění) a klasický důkaz na 3. bod. Úroveň 2 přidává jeho vypracování.

Pozor (častá chyba): Mez $\Omega(n \log n)$ platí jen pro *porovnávací* model; counting/radix ji nelámou „kouzlem“, ale jiným modelem (předpoklad o klíčích). $\log_2(n!) = \Theta(n \log n)$, ne $\Theta(n)$.

3 Specializace: Strojové učení (rozšíření)

Úloha 13. specializace UI-SU [úroveň 2] k-means ručně: dvě iterace a hodnota ztráty

Body v rovině: $P_1 = (1, 1)$, $P_2 = (2, 1)$, $P_3 = (4, 3)$, $P_4 = (5, 4)$. Spust k-means s $k = 2$ a počátečními centry $c_1 = (1, 1)$, $c_2 = (5, 4)$.

- 1 b** Provedte krok přiřazení (euklidovská vzdálenost).
- 2 b** Přepočítejte centra a proveďte druhou iteraci; rozhodněte, zda algoritmus zkonvergoval.
- 3 b** Spočítejte hodnotu účelové funkce $J = \sum_i \|x_i - \mu_{c(i)}\|^2$ ve výsledném rozdělení.

(a) Vzdálenosti k $c_1 = (1, 1)$ a $c_2 = (5, 4)$: P_1 : 0 vs 5; P_2 : 1 vs $\sqrt{18} \approx 4,24$; P_3 : $\sqrt{13} \approx 3,61$ vs $\sqrt{2} \approx 1,41$; P_4 : 5 vs 0. Přiřazení: $\{P_1, P_2\} \rightarrow c_1$, $\{P_3, P_4\} \rightarrow c_2$.

(b) Nová centra: $c_1 = (\frac{1+2}{2}, \frac{1+1}{2}) = (1,5, 1)$, $c_2 = (\frac{4+5}{2}, \frac{3+4}{2}) = (4,5, 3,5)$. Druhá iterace: P_1, P_2 jsou jasně blíže c_1 (vzdálenosti 0,5) než c_2 ; P_3, P_4 blíže c_2 . Přiřazení se nezměnilo $\Rightarrow$ konvergence.

(c) Čtverce vzdáleností k přiřazenému centru: c_1 : $\|P_1 - c_1\|^2 = 0,25$, $\|P_2 - c_1\|^2 = 0,25$; c_2 : $\|P_3 - c_2\|^2 = 0,25 + 0,25 = 0,5$, $\|P_4 - c_2\|^2 = 0,25 + 0,25 = 0,5$. $J = 0,25 + 0,25 + 0,5 + 0,5 = 1,5$.

Iterace = (1) přiřaď ke nejblížešmu centru, (2) přepočti centra na průměr přiřazených bodů. J = součet čtverců vzdáleností k centru, po každém kroku neroste. Konec, když se přiřazení nezmění.

Kalibrace: Numerický k-means je opakovaný typ (shlukování 44 %). Umět dvě iterace ručně = spolehlivé 2-3 body; tato úloha snižuje šanci na skóre ≤ 1 u shlukovací otázky.

Pozor (častá chyba): Vzdálenosti můžeš porovnávat přes čtverce (není třeba odmocňovat). Centrum je průměr, ne medián; remízy v přiřazení vyřeš pevným pravidlem.

Úloha 14. specializace UI-SU [úroveň 2] Rozhodovací strom: výpočet informačního zisku

Uzel obsahuje 6 příkladů, z toho 3 kladné a 3 záporné. Uvažte dva atributy: A rozdělí data na $A=0$: (2 kladné, 1 záporný) a $A=1$: (1 kladný, 2 záporné); B rozdělí data na $B=0$: (3 kladné, 0 záporných) a $B=1$: (0 kladných, 3 záporné).

- (a) **1 b** Spočítejte entropii kořene.
- (b) **2 b** Spočítejte informační zisk atributu A a atributu B .
- (c) **3 b** Který atribut zvolíte a proč? Co by udělalo prořezávání?

(a) $H(\text{kořen}) = -\frac{1}{2} \log_2 \frac{1}{2} - \frac{1}{2} \log_2 \frac{1}{2} = 1$ bit.

(b) Atribut A : obě větve mají rozdělení (2, 1), resp. (1, 2), tedy

$$H = -\frac{2}{3} \log_2 \frac{2}{3} - \frac{1}{3} \log_2 \frac{1}{3} = \frac{2}{3} \cdot 0,585 + \frac{1}{3} \cdot 1,585 = 0,918 \text{ bitu.}$$

Vážená entropie $= \frac{3}{6} \cdot 0,918 + \frac{3}{6} \cdot 0,918 = 0,918$, takže $IG(A) = 1 - 0,918 = 0,082$. Atribut B : obě větve jsou čisté, $H = 0$, vážená entropie 0, takže $IG(B) = 1 - 0 = 1$ bit.

(c) Zvolíme B (maximální informační zisk, dokonalé rozdělení). *Prořezávání*: kdyby další štěpení (např. podle A uvnitř větve) zlepšovalo jen trénovací chybu, ne validační, ponecháme list (post-pruning), aby strom negeneralizoval šum.

Tabulka 2.33: Informační zisk

$H = -\sum_k p_k \log_2 p_k$; pro (2, 1) vyjde 0,918. $IG = H(\text{rodič}) - \sum_j \frac{|S_j|}{|S|} H(S_j)$. Čisté listy $\Rightarrow H = 0 \Rightarrow$ maximální zisk. Vyber atribut s největším IG .

Kalibrace: Výpočet IG je opakovaný (rozhodovací stromy 33 %). Hodnoty $\log_2 \frac{1}{3} = -1,585$, $\log_2 \frac{2}{3} = -0,585$ je vhodné znát; tím se vyhneš skóre ≤ 1 .

Pozor (častá chyba): Informační zisk je *vážený* velikostmi větví. $\log_2$, ne $\ln$. Záporný argument logaritmu nehrozí (jen podíl v $(0, 1]$).

Úloha 15. specializace UI-SU [úroveň 2] Rekonstrukce matice záměn u nevyvážených tříd

Testovací množina má 1000 vzorků, z toho 5 % pozitivních. Klasifikátor má recall 0,8 a precision 0,5.

- (a) **1 b** Určete počet pozitivních a negativních a spočítejte TP a FN.
- (b) **2 b** Z precision dopočítejte FP a poté TN. Sestavte matici záměn.
- (c) **3 b** Spočítejte accuracy a F_1 a vysvětlete, proč je zde accuracy zavádějící.

(a) Pozitivních $P = 0,05 \cdot 1000 = 50$, negativních $N = 950$. $TP = \text{recall} \cdot P = 0,8 \cdot 50 = 40$, $FN = P - TP = 10$.

(b) Z precision $= \frac{TP}{TP+FP} = 0,5$ plyne $TP + FP = 80$, tedy $FP = 40$. $TN = N - FP = 950 - 40 =$

910. Matice záměn:

	$\hat{+}$	$\hat{-}$
$+$	40	10
$-$	40	910

(c) $\text{accuracy} = \frac{\text{TP}+\text{TN}}{1000} = \frac{950}{1000} = 0,95$. $F_1 = \frac{2 \cdot 0,5 \cdot 0,8}{0,5+0,8} = \frac{0,8}{1,3} \approx 0,615$. Accuracy 0,95 vypadá skvěle, ale triviální klasifikátor „vše negativní“ by měl accuracy 0,95 taky (950/1000) a nenašel by nic - proto se u nevyvážených tříd díváme na precision/recall/ F_1 .

Úloha 2. Vzdělávání strojů: metрики

TP = recall $\cdot$ P, FN = P – TP; z precision TP + FP = TP/precision, TN = N – FP. Accuracy u nevyvážených tříd klame (porovnej s „vše majoritní“).

Kalibrace: Tento přesný typ (rekonstrukce počtu z metrik) padl opakovaně (2023-léto, 2025-podzim). Nacvičit = jistá 2-3 z evaluační otázky.

Pozor (častá chyba): Jmenovatel precision jsou *predikované* pozitivní (TP + FP), recall *skutečné* pozitivní (TP + FN). Neplet P (skutečné pozitivní) s predikcemi.

Úloha 16. specializace UI-SU [úroveň 2] Lineární regrese ručně a vliv L2 regularizace

Data jednorozměrné regrese: $(x, y) \in \{(1, 1), (2, 2), (3, 2)\}$, model $\hat{y} = w_0 + w_1 x$.

- 1 b** Napište normální rovnice v maticovém tvaru.
- 2 b** Spočítejte řešení nejmenších čtverců w_0, w_1 .
- 3 b** Jak by se řešení změnilo s L2 regularizací (ridge) a proč? Uveďte upravené normální rovnice.

(a) S maticí $X = \begin{pmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \end{pmatrix}$ a $y = (1, 2, 2)^\top$ jsou normální rovnice $X^\top X w = X^\top y$, kde $X^\top X = \begin{pmatrix} 3 & 6 \\ 6 & 14 \end{pmatrix}$, $X^\top y = \begin{pmatrix} 5 \\ 11 \end{pmatrix}$.

(b) Snazší přes vzorce jednoduché regrese: $\bar{x} = 2$, $\bar{y} = \frac{5}{3}$. $w_1 = \frac{\sum(x - \bar{x})(y - \bar{y})}{\sum(x - \bar{x})^2} = \frac{(-1)(-\frac{2}{3}) + 0 + (1)(\frac{1}{3})}{1 + 0 + 1} = \frac{1}{2} = 0,5$. $w_0 = \bar{y} - w_1 \bar{x} = \frac{5}{3} - 0,5 \cdot 2 = \frac{2}{3} \approx 0,667$. Tedy $\hat{y} = 0,667 + 0,5x$.

(Kontrola maticově: $\det(X^\top X) = 3 \cdot 14 - 36 = 6$, $w = \frac{1}{6} \begin{pmatrix} 14 & -6 \\ -6 & 3 \end{pmatrix} \begin{pmatrix} 5 \\ 11 \end{pmatrix} = \frac{1}{6} \begin{pmatrix} 4 \\ 3 \end{pmatrix} = \begin{pmatrix} 0,667 \\ 0,5 \end{pmatrix}$.)

(c) Ridge minimalizuje $\|Xw - y\|^2 + \lambda \|w\|^2$, normální rovnice $(X^\top X + \lambda I)w = X^\top y$. S rostoucím λ se w_1 (a w_0 , neregularizuje-li se zvlášť) *smršťuje k nule*: matice $X^\top X + \lambda I$ je vždy regulární a dobře podmíněná, takže řešení existuje i při kolineárních datech a model méně přeučuje (menší rozptyl). Bias w_0 se obvykle *neregularizuje* (v penaltě se vynechá): $(X^\top X + \lambda D)w = X^\top y$ s $D = \text{diag}(0, 1, \dots, 1)$.

Úloha 3. Vzdělávání strojů: metricky

$w = (X^\top X)^{-1} X^\top y$; jednodušeji $w_1 = \frac{\sum(x - \bar{x})(y - \bar{y})}{\sum(x - \bar{x})^2}$, $w_0 = \bar{y} - w_1 \bar{x}$. Ridge: $(X^\top X + \lambda I)w = X^\top y$, smršťuje koeficienty.

Kalibrace: Ruční OLS / jeden ridge krok je opakovaný (regrese 67%). Tato úloha sytí kritickou podlahu specializace a snižuje šanci na skóre ≤ 1 .

Pozor (častá chyba): X musí mít sloupec jedniček pro bias. Vzorec pro w_1 má ve jmenovateli rozptyl x , ne kovarianci.

Úloha 17. specializace UI-SU [úroveň 2] Logistická regrese: jeden krok SGD

Binární logistická regrese s vahami $w = (w_0, w_1) = (0, 0)$ (s biasem). Trénovací příklad $x = (1, 2)$ (první složka je bias), skutečná třída $y = 1$, rychlost učení $\eta = 0,1$.

- 1 b** Spočítejte predikci $p = \sigma(w^\top x)$.
- 2 b** Spočítejte gradient ztráty na tomto příkladu a proveďte jeden krok SGD.
- 3 b** Spočítejte novou predikci na stejném bodě a ověřte, že se posunula správným směrem.

(a) $w^\top x = 0 \cdot 1 + 0 \cdot 2 = 0$, takže $p = \sigma(0) = \frac{1}{1+e^0} = 0,5$.

(b) Gradient NLL na jednom příkladu: $\nabla_w = (p - y)x = (0,5 - 1)(1, 2) = (-0,5, -1)$. Krok SGD:

$$w \leftarrow w - \eta \nabla_w = (0, 0) - 0,1 \cdot (-0,5, -1) = (0,05, 0,1).$$

(c) Nová predikce: $w^\top x = 0,05 \cdot 1 + 0,1 \cdot 2 = 0,25$, $p = \sigma(0,25) = \frac{1}{1+e^{-0,25}} \approx \frac{1}{1+0,779} \approx 0,562$. Pravděpodobnost třídy 1 vzrostla z 0,5 na 0,562, tedy směrem ke skutečné třídě $y = 1$. Správně.

$p = \sigma(w^\top x) = \frac{1}{1+e^{-w^\top x}}$. Gradient $(p - y)x$. SGD: $w \leftarrow w - \eta(p - y)x$. Při $y = 1$ a $p < 1$ je $(p - y) < 0$, takže váhy ve směru x rostou a p se zvyšuje.

Kalibrace: Jeden SGD krok logistické regrese je opakovaný (logistická regrese se zkoušela 2024-podzim, 2025-jaro). Sigmoid + gradient $(p - y)x$ zapaměti = jistá 2-3.

Pozor (častá chyba): Gradient je $(p - y)x$, ne $(y - p)x$ - pak by byl krok $w \leftarrow w + \eta(y - p)x$ (znaménko musí sedět se směrem minimalizace). $\sigma(0) = 0,5$.

Úloha 18. specializace UI-SU [úroveň 2] PCA: kovariance, vlastní rozklad, projekce

Centrovaná data mají kovarianční matici $C = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$.

- 1 b** Spočítejte vlastní čísla C a první hlavní komponentu (vlastní vektor).
- 2 b** Jaký podíl rozptylu vysvětluje první komponenta?
- 3 b** Na kterou osu data projektujete při redukci na 1 dimenzi a jak projekci spočtete?

(a) $\det(C - \lambda I) = (2 - \lambda)^2 - 1 = \lambda^2 - 4\lambda + 3 = (\lambda - 1)(\lambda - 3)$, tedy $\lambda_1 = 3$, $\lambda_2 = 1$. K $\lambda_1 = 3$: $(C - 3I) = \begin{pmatrix} -1 & 1 \\ 1 & -1 \end{pmatrix}$, vlastní vektor $v_1 = (1, 1)^\top$, normovaně $\frac{1}{\sqrt{2}}(1, 1)$. To je první hlavní komponenta.

(b) Vysvětlený rozptyl první komponenty $= \frac{\lambda_1}{\lambda_1 + \lambda_2} = \frac{3}{4} = 0,75$, tedy 75 %.

(c) Projektujeme na směr $v_1 = \frac{1}{\sqrt{2}}(1, 1)$ (největší vlastní číslo). Nová (1D) souřadnice bodu x je skalární součin $z = v_1^\top x = \frac{1}{\sqrt{2}}(x_1 + x_2)$. Tím zachováme maximum rozptylu (75 %) a zahodíme směr $(1, -1)$ s rozptylem 25 %.

Hlavní komponenty = vlastní vektory kovariance, seřazené podle vlastních čísel (= rozptylu podél nich). Vysvětlený rozptyl $= \lambda_i / \sum \lambda_j$. Projekce na PC: $z = v^\top x$. Před PCA centruj (a obvykle škáluj).

Kalibrace: Numerická PCA na 2D (kovariance -> vlastní čísla -> projekce) je vděčný typ (PCA 12 %, ale opakovaný jako vizuální/výpočetní). Sytí specializační podlahu.

Pozor (častá chyba): Komponenta s největším vlastním číslem nese nejvíc rozptylu. Vlastní

vektory normuj. PCA hledá rozptýl, ne oddělení tříd.

Úloha 19. specializace UI-SU [úroveň 2] SVM: geometrie hranice a vliv bodu

Dvě lineárně separabilní třídy v rovině: kladné body $(3, 3)$, $(4, 4)$, záporné body $(0, 0)$, $(1, 1)$.

- (a) **1 b** Popište, kudy povede rozdělující nadrovina s maximálním marginem a které body jsou podpůrné vektory. Načrtněte (slovně) hranici.
- (b) **2 b** Co se stane s hranicí, přidáme-li bod $(2, 2)$ s kladnou třídou? A co bod $(5, 5)$ s kladnou třídou daleko za hranicí?
- (c) **3 b** Kdy lineární SVM selže a jak pomůže RBF jádro?

(a) Body leží na přímce $y = x$; kladné jsou „nahore vpravo“, záporné „dole vlevo“. Maximálně marginová nadrovina je kolmá na spojnici nejbližších bodů protilehlých tříd, tedy přímka $x + y = c$ procházející středem mezi $(1, 1)$ a $(3, 3)$, tj. $x + y = 4$ (kolmá na směr $(1, 1)$). *Podpůrné vektory* jsou nejbližší body $(1, 1)$ a $(3, 3)$; body $(0, 0)$ a $(4, 4)$ jsou dál a hranici neurčují.

(b) Bod $(2, 2)$ leží přesně na hranici $x + y = 4$; jako *kladný* tedy leží uvnitř marginu (porušuje ho), stane se podpůrným vektorem a hranici *posune/zúží* (řešení se změní). Bod $(5, 5)$: $x + y = 10$, leží daleko v kladné oblasti za marginem, je správně klasifikovaný a není mezi nejbližšími - hranici proto *nezmění*. Obecně: body daleko a správně klasifikované (mimo margin) řešení neovlivní; mění ho jen body v marginu, resp. nejbližší body.

(c) Lineární SVM selže, nejsou-li třídy lineárně separabilní (např. XOR nebo soustředné kružnice). *RBF jádro* $K(x, z) = e^{-\gamma \|x - z\|^2}$ implicitně mapuje do vysokorozměrného prostoru, kde hranice může být nelineární (lokální, podle vzdálenosti k podpůrným vektorům); malé γ = hladká hranice, velké γ = klikatá (přeučení).

Maximálně marginová hranice je kolmá na spojnici nejbližších protilehlých bodů, vede jejich středem; ty body jsou podpůrné vektory. Body daleko a správně neovlivní řešení. Neseperabilní data $\rightarrow$ měkký margin (C) nebo nelineární jádro (RBF).

Kalibrace: Geometrická SVM otázka („nakreslete hranici, vliv přidání bodu, kdy RBF“) padla 2024-léto skoro doslova. Konceptuálně-geometrické zvládnutí = 2-3 body.

Pozor (častá chyba): Hranici určují jen podpůrné vektory; přidání bodu daleko za marginem nic nezmění, přidání do marginu ano. Velké γ /velké C = přeučení.

Úloha 20. specializace UI-SU [úroveň 2] ROC křivka a AUC z konkrétních skóre

Klasifikátor přiřadil skóre: pozitivní příklady $\{0,9, 0,6, 0,4\}$, negativní příklady $\{0,7, 0,3, 0,2\}$ (tedy $P = 3$, $N = 3$).

- (a) **1 b** Pro klesající práh spočtěte body ROC (TPR, FPR).
- (b) **2 b** Načrtněte (popište) tvar ROC křivky.
- (c) **3 b** Spočtěte AUC a interpretujte ji.

(a) Setříděno sestupně: $0,9(+), 0,7(-), 0,6(+), 0,4(+), 0,3(-), 0,2(-)$. Predikuj „+“ při skóre $\geq$

práh; $TPR = TP/3$, $FPR = FP/3$:

práh	TP	FP	TPR	FPR
0,9	1	0	0,33	0
0,7	1	1	0,33	0,33
0,6	2	1	0,67	0,33
0,4	3	1	1,00	0,33
0,3	3	2	1,00	0,67
0,2	3	3	1,00	1,00

(b) Křivka jde z (0,0) schody nahoru a doprava do (1,1); nejprve stoupá strmě (zachytí 2 pozitivní při FPR 0,33), pak doroste TPR na 1 a nakonec dobírá falešně pozitivní. Leží nad diagonálou (lepší než náhoda).

(c) AUC = pravděpodobnost, že náhodný pozitivní dostane vyšší skóre než náhodný negativní. Spočítáme přes dvojice: $0,9 >$ všechny 3 negativní; $0,6 > \{0,3, 0,2\}$ (2); $0,4 > \{0,3, 0,2\}$ (2). Celkem $3 + 2 + 2 = 7$ z 9 dvojic. $AUC = \frac{7}{9} \approx 0,78$. Tedy klasifikátor řadí pozitivní nad negativní v 78 % případu (1 = ideál, 0,5 = náhoda).

Úloha 20: ROC a AUC (rozšíření)

ROC = TPR vs FPR při klesajícím prahu; každý pozitivní zvýší TPR, každý negativní FPR.
AUC = podíl dvojic (pozitivní, negativní), kde pozitivní má vyšší skóre = $P(\text{skóre}^+ > \text{skóre}^-)$.

Kalibrace: ROC/AUC z konkrétních skóre je legální numerický typ evaluační otázky (44 %). Doplnuje rekonstrukci matice záměn a snižuje šanci na skóre ≤ 1 .

Pozor (častá chyba): ROC vynáší TPR proti FPR, ne proti precision (to je PR křivka). AUC přes počítání dvojic je rychlejší než integrace.

4 Specializace: Základy UI (rozšíření)

Úloha 21. specializace UI-SU [úroveň 2] Bayesovská síť: inference enumerací

Síť: dvě nezávislé příčiny A, B a společný následek C (hrany $A \rightarrow C$, $B \rightarrow C$). $P(A) = 0,2$, $P(B) = 0,5$ a $P(C=t \mid A, B)$: $AtBt: 0,9$; $AtBf: 0,8$; $AfBt: 0,7$; $AfBf: 0,1$.

- 1 b** Napište faktorizaci sdružené distribuce.
- 2 b** Spočítejte $P(A=t, C=t)$ a $P(A=f, C=t)$ (vysčítání přes B).
- 3 b** Spočítejte posterior $P(A=t \mid C=t)$.

(a) $P(A, B, C) = P(A) P(B) P(C \mid A, B)$ (A, B jsou kořeny bez rodičů, nezávislé).

(b) Vysčítáme přes $B \in \{t, f\}$:

$$P(A=t, C=t) = P(A=t) \sum_B P(B) P(C=t \mid A=t, B) = 0,2 (0,5 \cdot 0,9 + 0,5 \cdot 0,8) = 0,2 \cdot 0,85 = 0,17.$$

$$P(A=f, C=t) = 0,8 (0,5 \cdot 0,7 + 0,5 \cdot 0,1) = 0,8 \cdot 0,40 = 0,32.$$

(c) $P(C=t) = 0,17 + 0,32 = 0,49$, takže

$$P(A=t \mid C=t) = \frac{0,17}{0,49} \approx 0,347.$$

$P(\cdot) = \prod_i P(X_i \mid \text{rodiče})$. Dotaz: $P(Q \mid e) \propto \sum_{\text{skryté}} \prod(\text{faktory})$; spočti $P(Q, e)$ pro každou hodnotu Q a normuj. Pozorování $C=t$ „nahoru“ zvýší pravděpodobnost příčin.

Kalibrace: Numerická inference v Bayes síti (enumerace) padla 2024-léto. Vysčítání + normalizace zpaměti = 2-3 body z AI slotu specializace.

Pozor (častá chyba): Nezapomeň normovat ($\div P(e)$). Sčítáš *součiny* faktoru přes skryté proměnné, ne pravděpodobnosti zvlášť.

Úloha 22. specializace UI-SU [úroveň 2] HMM: dvoukroková filtrace

Skrytý stav „prší“ $R \in \{t, f\}$. Přejchody: $P(R_t=t \mid R_{t-1}=t) = 0,7$, $P(R_t=t \mid R_{t-1}=f) = 0,3$. Emise (dešťníky): $P(U=t \mid R=t) = 0,9$, $P(U=t \mid R=f) = 0,2$. Prior $P(R_0=t) = 0,5$. Pozorování $U_1=t$, $U_2=t$.

- 1 b** Spočtete filtraci $P(R_1 \mid U_1=t)$ (krok predikce + korekce).
- 2 b** Spočtete $P(R_2 \mid U_1=t, U_2=t)$.
- 3 b** Napište obecný rekurentní vzorec, který jste použili.

(a) *Predikce* z prioru: $P(R_1=t) = 0,7 \cdot 0,5 + 0,3 \cdot 0,5 = 0,5$, $P(R_1=f) = 0,5$. *Korekce* emisí $U_1=t$: $\propto (0,9 \cdot 0,5, 0,2 \cdot 0,5) = (0,45, 0,10)$. Normalizace ($/0,55$): $P(R_1=t \mid U_1) = 0,818$, $P(R_1=f \mid U_1) = 0,182$.

(b) *Predikce*: $P(R_2=t) = 0,7 \cdot 0,818 + 0,3 \cdot 0,182 = 0,573 + 0,055 = 0,627$, $P(R_2=f) = 0,373$. *Korekce* $U_2=t$: $\propto (0,9 \cdot 0,627, 0,2 \cdot 0,373) = (0,564, 0,075)$. Normalizace ($/0,639$): $P(R_2=t \mid U_1, U_2) \approx 0,883$, $P(R_2=f \mid \cdot) \approx 0,117$.

(c) $P(R_t \mid e_{1:t}) \propto P(e_t \mid R_t) \sum_{r_{t-1}} P(R_t \mid r_{t-1}) P(r_{t-1} \mid e_{1:t-1})$ (predikce přes přechod, korekce emisí, normalizace).

Filtrace = střidej predikci (násob přechodovou maticí) a korekci (násob emisí pozorování) a normuj. Dva dešťníky táhnou „prší“ nahoru: $0,5 \rightarrow 0,818 \rightarrow 0,883$.

Kalibrace: Numerická filtrace HMM padla 2023-léto. Dvoukrokový výpočet zpaměti = 2-3 body z AI slotu; HMM 12 %.

Pozor (častá chyba): Pořadí: nejdřív predikce (přechod), pak korekce (emise), pak normalizace. Emisi nesmíš použít dřív než přechod.

Úloha 23. specializace UI-SU [úroveň 2] EM algoritmus: jedna iterace

Směs dvou shluků $Z \in \{1, 2\}$ nad binárním příznakem $x \in \{0, 1\}$. Aktuální parametry: $\pi = (0,5, 0,5)$, $p(x=1 \mid Z=1) = 0,8$, $p(x=1 \mid Z=2) = 0,4$. Data: $x_1 = 1$, $x_2 = 0$.

- 1 b** E-krok: spočtete responsibility $r_{i1} = P(Z=1 \mid x_i)$ pro oba body.
- 2 b** M-krok: aktualizujte váhy π_1, π_2 .
- 3 b** M-krok: aktualizujte $p(x=1 \mid Z=1)$ a $p(x=1 \mid Z=2)$.

(a) $r_{i1} = \frac{\pi_1 p(x_i \mid 1)}{\pi_1 p(x_i \mid 1) + \pi_2 p(x_i \mid 2)}$. Pro $x_1=1$: $\frac{0,5 \cdot 0,8}{0,5 \cdot 0,8 + 0,5 \cdot 0,4} = \frac{0,4}{0,6} = 0,667$, takže $r_{11} = 0,667$, $r_{12} = 0,333$. Pro $x_2=0$ (použij $p(x=0 \mid 1) = 0,2$, $p(x=0 \mid 2) = 0,6$): $\frac{0,5 \cdot 0,2}{0,5 \cdot 0,2 + 0,5 \cdot 0,6} =$

$$\frac{0,1}{0,4} = 0,25, \text{ takže } r_{21} = 0,25, r_{22} = 0,75.$$

$$(b) \pi_k = \frac{1}{n} \sum_i r_{ik}: \pi_1 = \frac{0,667+0,25}{2} = 0,458, \pi_2 = 0,542.$$

$$(c) p(x=1 | Z=k) = \frac{\sum_i r_{ik} [x_i=1]}{\sum_i r_{ik}}:$$

$$p(x=1 | 1) = \frac{0,667 \cdot 1 + 0,25 \cdot 0}{0,667 + 0,25} = \frac{0,667}{0,917} \approx 0,727, \quad p(x=1 | 2) = \frac{0,333}{0,333 + 0,75} = \frac{0,333}{1,083} \approx 0,308.$$

Shluk 1 se přiosřil k $x=1$, shluk 2 k $x=0$.

Indice 2 body (období září 2025 – říjen 2025)

E-krok: $r_{ik} = \frac{\pi_k p(x_i | \theta_k)}{\sum_j \pi_j p(x_i | \theta_j)}$. M-krok: $\pi_k = \frac{1}{n} \sum_i r_{ik}$, parametry = responsibilitami vážené (relativní) četnosti / průměry.

Kalibrace: Jeden EM update (responsibility + M-krok) padl 2025-léto. Toto je přesný typ; nacvičit = 2-3 body z AI slotu.

Pozor (častá chyba): Responsibility se normuje přes shluky. M-krok je *vážený* responsibilitami, ne prosté četnosti. Pro $x=0$ použij $p(x=0 | \cdot) = 1 - p(x=1 | \cdot)$.

Úloha 24. specializace UI-SU [úroveň 2] Minimax, alfa-beta a A* na konkrétním příkladu

- 1 b** Strom: kořen MAX má dva syny MIN. Levý MIN má listy 3, 5; pravý MIN má listy 2, 9. Spočítejte minimaxovou hodnotu.
- 2 b** Ukažte, kterou hodnotu alfa-beta ořeže (prochází zleva doprava).
- 3 b** V grafu s hranami $S-A=1, A-B=2, A-G=5, B-G=1$ a heuristikou $h(S)=4, h(A)=3, h(B)=1, h(G)=0$ najděte A* cestu z S do G .

(a) Levý MIN = $\min(3, 5) = 3$, pravý MIN = $\min(2, 9) = 2$. Kořen MAX = $\max(3, 2) = 3$.

(b) Po vyhodnocení levého podstromu je $\alpha = 3$. V pravém MIN se přečte první list 2; protože hodnota MIN uzlu bude $\leq 2 \leq \alpha = 3$, MAX si ho stejně nevybere - druhý list 9 se *ořízne* (alfa cutoff). Výsledek 3 je stejný jako u minimaxu.

(c) $f = g + h$. Start S : $g=0, f=4$. Rozvoj S : A $g=1, f=1+3=4$; B přes S neexistuje hrana, jen přes A . Rozvoj A (nejmenší $f=4$): B $g=1+2=3, f=3+1=4$; G $g=1+5=6, f=6$. Rozvoj B ($f=4$): G $g=3+1=4, f=4$. Rozvoj G ($f=4$) = cíl. Cesta $S \rightarrow A \rightarrow B \rightarrow G$ s cenou 4 (lepší než $S \rightarrow A \rightarrow G$ s cenou 6; přímá hrana $S-B$ v grafu není).

Minimax: listy nahoru, MAX bere max, MIN min. Alfa-beta ořeže větve, jakmile $\alpha \geq \beta$. A* rozvíjí nejmenší $f=g+h$; s přípustnou/konzistentní h je optimální.

Kalibrace: Ruční alfa-beta a A* jsou opakované AI typy (hry 22 %, prohlédávání 15 %). Jeden vyřešený strom + graf = 2-3 body z AI slotu.

Pozor (častá chyba): Alfa-beta nemění výsledek, jen ořezává. U A* musí být h přípustná, jinak nemusí najít optimum; rozvíjej vždy uzel s nejmenším f .

Úloha 25. specializace UI-SU [úroveň 2] Bayesovské učení: posterior a Bayes-optimal predikce

Pytlík je jedné ze dvou hypotéz: h_1 s $P(\text{třešeň}) = 0,8$, nebo h_2 s $P(\text{třešeň}) = 0,4$. Prior $P(h_1) = P(h_2) = 0,5$. Vytáhneme jeden bonbon a je to *třešeň*.

- 1 b** Určete ML a MAP hypotézu po tomto pozorování.
- 2 b** Spočítejte posterior $P(h_1 \mid \text{třešeň})$ a $P(h_2 \mid \text{třešeň})$.
- 3 b** Spočítejte Bayes-optimal predikci $P(\text{další} = \text{třešeň} \mid \text{data})$.

(a) Věrohodnost pozorování „třešeň”: $P(\text{tř} \mid h_1) = 0,8 > P(\text{tř} \mid h_2) = 0,4$, takže ML hypotéza je h_1 . Prior je uniformní, takže $MAP = ML = h_1$.

(b) $P(h_1 \mid \text{tř}) \propto 0,5 \cdot 0,8 = 0,4$; $P(h_2 \mid \text{tř}) \propto 0,5 \cdot 0,4 = 0,2$. Normalizace ($/0,6$): $P(h_1 \mid \text{tř}) = \frac{0,4}{0,6} = 0,667$, $P(h_2 \mid \text{tř}) = 0,333$.

(c) Bayes-optimal váží přes hypotézy:

$$P(\text{další}=\text{tř} \mid \text{data}) = \sum_h P(\text{tř} \mid h)P(h \mid \text{data}) = 0,8 \cdot 0,667 + 0,4 \cdot 0,333 = 0,533 + 0,133 = 0,667.$$

(Pozn.: predikce přes MAP samotnou by dala 0,8; Bayes-optimal je obezřetnější, protože h_2 ještě není vyloučena.)

Posterior $\propto$ věrohodnost $\times$ prior, pak normuj. ML = arg max věrohodnost, MAP = arg max posterior. Bayes-optimal predikce = $\sum_h P(\cdot \mid h)P(h \mid \text{data})$ (ne jen přes jednu hypotézu).

Kalibrace: Posterior + Bayes-optimal predikce padly 2025-jaro. Přesný typ; nacvičit = 2-3 body z AI slotu.

Pozor (častá chyba): Bayes-optimal $\neq$ predikce přes MAP hypotézu - váží přes *všechny* hypotézy jejich posteriorem. Nezapomeň normovat posterior.

Úloha 26. specializace UI-SU [úroveň 2] AC-3 krok za krokem

Proměnné X, Y, Z s doménami $\{1, 2, 3, 4\}$ a omezeními $X < Y$ a $Y < Z$. Provedte AC-3 a vedte frontu hran.

- 1 b** Vypište počáteční frontu hran.
- 2 b** Zpracujte hrany a u každé revize uveďte zúžení domény a nově přidané hrany.
- 3 b** Uveďte výsledné domény a vysvětlete, proč musela být znovu zařazena hrana (X, Y) .

(a) Hrany (obě orientace každého omezení): $(X, Y), (Y, X), (Y, Z), (Z, Y)$.

(b)

- (X, Y) [$X < Y$]: $X=4$ nemá $Y > 4 \Rightarrow D_X = \{1, 2, 3\}$. (jediný soused X je Y = právě porovnávaná hrana, nic nepřidáváme)
- (Y, X) [pro Y existuje $X < Y$]: $Y=1$ nemá $X < 1 \Rightarrow D_Y = \{2, 3, 4\}$. (přidej (Z, Y) ; soused X je právě porovnávaný)
- (Y, Z) [$Y < Z$]: $Y=4$ nemá $Z > 4 \Rightarrow D_Y = \{2, 3\}$. (přidej (X, Y) ; soused Z je právě porovnávaný)
- (Z, Y) [pro Z existuje $Y < Z$]: $Z=1$ (žádné $Y < 1$) a $Z=2$ (žádné $Y < 2$ v $\{2, 3\}$) vypadnou $\Rightarrow D_Z = \{3, 4\}$. (jediný soused Z je Y = právě porovnávaná hrana)
- (X, Y) (znovu): $X=3$ nemá $Y > 3$ v $\{2, 3\} \Rightarrow D_X = \{1, 2\}$.

(c) Výsledek: $D_X = \{1, 2\}$, $D_Y = \{2, 3\}$, $D_Z = \{3, 4\}$. Hrana (X, Y) se musela zařadit znovu, protože při revizi (Y, Z) se zmenšila doména Y ; tím mohly ztratit podporu hodnoty v X , které

se na zúžené Y odvolávaly (proto AC-3 vrací do fronty hrany (X_k, Y) od sousedu X_k změněné proměnné, kromě právě porovnávané).

AC-3: fronta orientovaných hran; REVISE(X_i, X_j) smaže z D_i hodnoty bez podpory v D_j . Zmenší-li se D_i , vrať do fronty hrany (X_k, X_i) pro sousedy $X_k \neq X_j$. Konec při prázdné frontě (nebo prázdné doméně = bez řešení). Složitost $O(ed^3)$.

Kalibrace: Krokování AC-3 padlo 2026-jaro. Vedení fronty a šíření z paměti = 2-3 body z AI slotu (CSP 22 %).

Pozor (častá chyba): Po zúžení domény se musí znovu prověřit *sousední* hrany - na to se zapomíná. Hranová konzistence ani po doběhnutí nezaručuje řešení.

Úloha 27. specializace UI-SU [úroveň 2] MDP: iterace hodnot

Stavy A, B a cíl C (terminální, $V(C) = 0$). Diskont $\gamma = 0,9$. Z A jsou dvě akce: „do B” (deterministicky do B , odměna -1) a „přímo” (deterministicky do C , odměna -3). Z B akce „do C” (do C , odměna -1).

- (a) **1 b** Napište Bellmanovu rovnici pro $V^*(A)$ a $V^*(B)$.
- (b) **2 b** Provedte iteraci hodnot z $V_0 \equiv 0$ (dva sweepy).
- (c) **3 b** Uveďte optimální hodnoty a strategii.

(a) $V^*(B) = -1 + \gamma V^*(C) = -1$. $V^*(A) = \max\{-1 + \gamma V^*(B), -3 + \gamma V^*(C)\}$.

(b) $V_0(A) = V_0(B) = 0$. Sweep 1: $V_1(B) = -1 + 0,9 \cdot 0 = -1$; $V_1(A) = \max\{-1 + 0,9 \cdot 0, -3 + 0,9 \cdot 0\} = \max\{-1, -3\} = -1$ (akce „do B”). Sweep 2: $V_2(B) = -1$; $V_2(A) = \max\{-1 + 0,9 \cdot (-1), -3\} = \max\{-1,9, -3\} = -1,9$ (akce „do B”). Sweep 3 by dal totéž ($V_3(A) = \max\{-1 + 0,9 \cdot (-1), -3\} = -1,9$) $\Rightarrow$ konvergence.

(c) $V^*(B) = -1$, $V^*(A) = -1,9$. Optimální strategie: z A jdi „do B”, z B jdi „do C” (cesta $A \rightarrow B \rightarrow C$ s celkovou diskontovanou odměnou $-1,9$ je lepší než přímo $A \rightarrow C$ s -3).

Bellman: $V^*(s) = \max_a \sum_{s'} P(s' | s, a)[R + \gamma V^*(s')]$. Iterace hodnot = opakuj tento update pro všechny stavy do konvergence; strategie = $\arg \max_a$.

Kalibrace: Bellmanova rovnice / iterace hodnot padla 2025-léto. Jeden-dva sweepy ručně = 2-3 body z AI slotu (MDP 15 %).

Pozor (častá chyba): Diskont γ násobí *hodnotu následníka*, ne odměnu kroku. U optima je $\max_a$ (u dané strategie jen ta jedna akce).